# Limbaje Formale, Automate și Compilatoare

Curs 1

2016-17

# Limbaje Formale, Automate și Compilatoare - Curs 1

- Prezentare curs
- 2 Limbaje formale
- Mecanisme de generare a limbajelor: gramatici
- 4 lerarhia lui Chomsky
- Limbaje şi gramatici de tip 3 (regulate)
- 6 Proprietăți de închidere pentru familia de limbaje regulate

### Limbaje Formale, Automate și Compilatoare

#### Titulari curs:

O. Captarencu: otto@info.uaic.iasi.ro

```
http://profs.info.uaic.ro/~otto/lfac.html
```

A. Moruz:mmoruz@info.uaic.ro

#### Sistem evaluare

- 7 seminarii, 6 laboratoare;
- AS = activitatea la seminar (max 10 puncte);
- AL = activitatea la laborator (max 10 puncte);
- T1,T2 teste scrise în săptămânile 8, respectiv în sesiune;
  Punctajul final se obţine astfel:

$$P = 3 * AS + 3 * AL + 2 * T1 + 2 * T2$$

- Condiţii miminale de promovare:  $AS \ge 5$ ,  $AL \ge 5$ ,  $T1 \ge 4$ ,  $T2 \ge 4$ ;
- Punctaj minim pentru promovare: P ≥ 50;
- Nota finală se va stabili conform criteriilor ECTS;

### Sistem evaluare

- AS = activitatea la seminar (max 10 puncte):
  - două teste scrise
  - până la 2 puncte bonus pentru activitatea din timpul seminarului
- AL = activitatea la laborator (max 10 puncte):
  - 1 test laborator, 1 proiect (note de la 0 la 10)
  - AL = media celor 2 note

### Tematica cursului (partea I)

- Limbaje şi gramatici
- Limbaje regulate; gramatici, automate, expresii regulate
- Limbaje independente de context; gramatici, automate pushdown

### Tematica cursului (partea II)

- Limbaje de programare: proiectare şi implementare
- Analiza lexicală
- Analiza sintactică
- Traducere în cod intermediar

#### Tematica seminarului

- Exemple de limbaje şi gramatici
- Automate finite deterministe, nedeterministe, cu epsilon-tranziţii -Exemple
- Expresii regulate
- Gramatici independente de context, arbori de derivare, eliminarea simbolurilor inutile, eliminarea regulilor de ştergere, a redenumirilor
- Forma normală Chomsky, algoritmul CYK
- Automate pushdown exemple

#### Tematica laboratorului

- Analiza lexicală folosind instrumente de tip LEX
- Analiza sintactică folosind instrumente de tip YACC
- Interpretor construit cu LEX şi YACC

# Bibliografie (selecţii)

- A. V. Aho, M. S. Lam, R. Sethi, J. D. Ullman: Compilers:
  Principles, Techniques, and Tools. Boston: Addison-Wesley, 2007
- Gh. Grigoras. Constructia compilatoarelor Algoritmi fundamentali, Ed. Universitatii Al. I. "Cuza Iasi", ISBN 973-703-084-2, 274 pg., 2005
- Mopcroft, John E.; Motwani, Rajeev; Ullman, Jeffrey D. (2006). Introduction to Automata Theory, Languages, and Computation (3rd ed.). Addison-Wesley
- J. Toader Limbaje formale şi automate, Editura Matrix Rom, Bucuresti, 1999.
- J. Toader, S. Andrei Limbaje formale şi teoria automatelor. Teorie şi practică, Editura Universitatii "Al. I. Cuza", Iasi, 2002.

# Limbaje Formale, Automate și Compilatoare - Curs 1

- Prezentare curs
- 2 Limbaje formale
- Mecanisme de generare a limbajelor: gramatici
- Ierarhia lui Chomsky
- 5 Limbaje și gramatici de tip 3 (regulate)
- 6 Proprietăți de închidere pentru familia de limbaje regulate

• Alfabet: V o multime finită (elementele lui V = simboluri )

- Alfabet: V o mulţime finită (elementele lui V = simboluri )
- Cuvânt: şir finit de simboluri
  - cuvântul nul este notat cu ε sau λ.

- Alfabet: V o multime finită (elementele lui V = simboluri )
- Cuvânt: şir finit de simboluri
  - cuvântul nul este notat cu ε sau λ.
- Lungimea unui cuvânt u: numarul simbolurilor sale. Notaţie: |u|.

$$|\epsilon| = 0$$

- Alfabet: V o mulţime finită (elementele lui V = simboluri )
- Cuvânt: şir finit de simboluri
  - cuvântul nul este notat cu ε sau λ.
- Lungimea unui cuvânt u: numarul simbolurilor sale. Notație: |u|.

$$|\epsilon| = 0$$

•  $V^*$  - multimea tuturor cuvintelor peste alfabetul V, inclusiv  $\epsilon$ .

$$\{0,1\}^* = \{\epsilon, 0, 1, 00, 01, 10, 11, 000, 001, \ldots\}$$

- Alfabet: V o mulţime finită (elementele lui V = simboluri )
- Cuvânt: şir finit de simboluri
  - cuvântul nul este notat cu  $\epsilon$  sau  $\lambda$ .
- ullet Lungimea unui cuvânt u: numarul simbolurilor sale. Notație: |u|.

$$|\epsilon| = 0$$

ullet V\* - multimea tuturor cuvintelor peste alfabetul V, inclusiv  $\epsilon$ .

$$\{0,1\}^* = \{\epsilon,0,1,00,01,10,11,000,001,\ldots\}$$

V<sup>+</sup> - multimea tuturor cuvintelor nenule peste alfabetul V

$$\{0,1\}^+ = \{0,1,00,01,10,11,000,001,\ldots\}$$

$$x = 0100, y = 100, x \cdot y = 0100100$$
  
 $x = 000, y = \epsilon, x \cdot y = 000$ 

Concatenarea a doua cuvinte x, y: cuvântul x · y obţinut din simbolurile lui x, în ordinea în care apar, urmate de cele ale lui y de asemenea în ordinea în care apar:

$$x = 0100, y = 100, x \cdot y = 0100100$$
  
 $x = 000, y = \epsilon, x \cdot y = 000$ 

Concatenarea este asociativă

$$x = 0100, y = 100, x \cdot y = 0100100$$
  
 $x = 000, y = \epsilon, x \cdot y = 000$ 

- Concatenarea este asociativă
- $(V^*, \cdot)$  este monoid ( $\epsilon$  este element neutru), se numeşte monoidul liber generat de V.

$$x = 0100, y = 100, x \cdot y = 0100100$$
  
 $x = 000, y = \epsilon, x \cdot y = 000$ 

- Concatenarea este asociativă
- $(V^*, \cdot)$  este monoid ( $\epsilon$  este element neutru), se numeşte monoidul liber generat de V.
- Cuvântul v este un prefix al cuvântului u dacă ∃w ∈ V\* : u = vw;
  dacă w ∈ V<sup>+</sup> , atunci v este un prefix propriu al lui u.

$$x = 0100, y = 100, x \cdot y = 0100100$$
  
 $x = 000, y = \epsilon, x \cdot y = 000$ 

- Concatenarea este asociativă
- $(V^*, \cdot)$  este monoid ( $\epsilon$  este element neutru), se numeşte monoidul liber generat de V.
- Cuvântul v este un prefix al cuvântului u dacă  $\exists w \in V^* : u = vw$ ; dacă  $w \in V^+$ , atunci v este un prefix propriu al lui u.
- Cuvântul v este un sufix al cuvântului u dacă  $\exists w \in V^* : u = wv$ ; dacă  $w \in V^+$ , atunci v este un sufix propriu al lui u.

- Fie V un alfabet. O submulţime L ⊆ V\* este un limbaj (formal) peste alfabetul V (sau V-limbaj) dacă L are o descriere (matematică) finită.
- O descriere poate fi:

- Fie V un alfabet. O submulţime L ⊆ V\* este un limbaj (formal) peste alfabetul V (sau V-limbaj) dacă L are o descriere (matematică) finită.
- O descriere poate fi:
  - neformală (în limbaj natural):
    - multimea cuvintelor peste alfabetul {0, 1} care contin un numar par de 0.
    - $L = \{x \in V^+ : |x| \text{ este par}\}.$
    - $\bullet \ \{a^nb^n|n\in N\}.$
    - $\{w \in \{0,1\}^* | w \text{ se termina in } 00\}.$

- Fie V un alfabet. O submulţime L ⊆ V\* este un limbaj (formal) peste alfabetul V (sau V-limbaj) dacă L are o descriere (matematică) finită.
- O descriere poate fi:
  - neformală (în limbaj natural):
    - multimea cuvintelor peste alfabetul {0,1} care contin un numar par de 0.
    - $L = \{x \in V^+ : |x| \text{ este par}\}.$
    - $\{a^nb^n|n\in N\}.$
    - $\{w \in \{0,1\}^* | w \text{ se termina in } 00\}.$
  - formală (descriere matematică):
    - o descriere inductivă a cuvintelor
    - o descriere generativă a cuvintelor (gramatică generativă)
    - o descriere a unei metode de recunoaştere a cuvintelor din limbaj (automat finit, automat pushdown, etc.)

# Operații cu limbaje

- Operatiile cu multimi (reuniune, intersectie etc)
- Produs de limbaje:  $L_1 \cdot L_2 = \{u \cdot v | u \in L_1, v \in L_2\}$
- Iteraţia (produsul Kleene):  $L^* = \bigcup_{n>0} L^n$ , unde:
  - $L^0 = \{\epsilon\}$
  - $\bullet L^{n+1} = L^n \cdot L$
- $L^R = \{w^R | w \in L\}$ ; dacă  $w = a_1 a_2 \dots a_n$ , atunci  $w^R = a_n \dots a_2 a_1$

# Limbaje Formale, Automate și Compilatoare - Curs 1

- Prezentare curs
- Limbaje formale
- Mecanisme de generare a limbajelor: gramatici
- 4 lerarhia lui Chomsky
- 5 Limbaje şi gramatici de tip 3 (regulate)
- 6 Proprietăți de închidere pentru familia de limbaje regulate

#### Gramatici

#### Definiție 1

O gramatica este un sistem G = (N, T, S, P), unde:

- N şi T sunt două alfabete disjuncte:
  - N este multimea neterminalilor
  - T este multimea terminalilor
- S ∈ N este simbolul de start (neterminalul iniţial)
- P este o multime finita de reguli (producţii) de forma  $x \to y$ , unde  $x, y \in (N \cup T)^*$  şi x conţine cel puţin un neterminal.

### Derivare

#### Definiție 2

Fie G = (N, T, S, P) o gramatica şi  $u, v \in (N \cup T)^*$ . Spunem că v este derivat direct (într-un pas) de la u prin aplicarea regulii  $x \to y$ , şi notăm  $u \Rightarrow v$ , dacă  $\exists p, q \in (N \cup T)^*$  astfel încât u = pxq și v = pyq.

### Derivare

#### Definiție 2

Fie G = (N, T, S, P) o gramatica şi  $u, v \in (N \cup T)^*$ . Spunem că v este derivat direct (într-un pas) de la u prin aplicarea regulii  $x \to y$ , şi notăm  $u \Rightarrow v$ , dacă  $\exists p, q \in (N \cup T)^*$  astfel încât u = pxq şi v = pyq.

• Daca  $u_1 \Rightarrow u_2 \dots \Rightarrow u_n, n > 1$ , spunem ca  $u_n$  este derivat din  $u_1$  în G si notam  $u_1 \Rightarrow^+ u_n$ .

#### **Derivare**

#### Definiție 2

Fie G = (N, T, S, P) o gramatica şi  $u, v \in (N \cup T)^*$ . Spunem că v este derivat direct (într-un pas) de la u prin aplicarea regulii  $x \to y$ , şi notăm  $u \Rightarrow v$ , dacă  $\exists p, q \in (N \cup T)^*$  astfel încât u = pxq şi v = pyq.

- Daca  $u_1 \Rightarrow u_2 \ldots \Rightarrow u_n, n > 1$ , spunem ca  $u_n$  este derivat din  $u_1$  în G şi notam  $u_1 \Rightarrow^+ u_n$ .
- Scriem  $u \Rightarrow^* v$  dacă  $u \Rightarrow^+ v$  sau u = v.

### Limbaj generat

#### Definiție 3

Limbajul generat de gramatica G este:

$$L(G) = \{ w \in T^* | S \Rightarrow^+ w \}$$

# Limbaj generat

#### Definiție 3

Limbajul generat de gramatica G este:

$$L(G) = \{ w \in T^* | S \Rightarrow^+ w \}$$

#### Definiție 4

Două gramatici  $G_1$  și  $G_2$  sunt echivalente dacă  $L(G_1) = L(G_2)$ .

### Exemplu

- $L = \{a^n b^{2n} | n \ge 1\}$
- Definiţia inductivă:
  - abb ∈ L
  - Daca  $X \in L$ , atunci  $aXbb \in L$
  - Nici un alt cuvânt nu face parte din L

### Exemplu

- $L = \{a^n b^{2n} | n \ge 1\}$
- Definiţia inductivă:
  - abb ∈ L
  - Daca  $X \in L$ , atunci  $aXbb \in L$
  - Nici un alt cuvânt nu face parte din L
- Definiţia generativă:
  - $G = (\{X\}, \{a, b\}, X, P)$ , unde  $P = \{X \rightarrow aXbb, X \rightarrow abb\}$
  - Derivarea cuvântului a<sup>3</sup>b<sup>6</sup>:

$$X \Rightarrow aXbb \Rightarrow a(aXbb)bb \Rightarrow aa(abb)bbbb$$

# Exemplu

- $L = \{a^n b^n c^n | n \ge 1\}$
- $\bullet = (N, T, S, P), N = \{S, X\}, T = \{a, b, c\}, P \text{ constă din:}$ 
  - $\bigcirc$  S  $\rightarrow$  abc
  - $\circled{S} \rightarrow aSXc$

  - $\bigcirc$  bX  $\rightarrow$  bb
- Derivarea cuvântului a<sup>3</sup>b<sup>3</sup>c<sup>3</sup>:
  - $S \Rightarrow^{(2)} a\underline{S}Xc \Rightarrow^{(2)} aa\underline{S}XcXc \Rightarrow^{(1)} aaab\underline{c}XcXc \Rightarrow^{(3)}$  $aaa\underline{b}XccXc \Rightarrow^{(4)} aaabbc\underline{c}Xc \Rightarrow^{(3)} aaabb\underline{c}Xcc \Rightarrow^{(3)}$  $aaabbXccc \Rightarrow^{(4)} aaabbbccc = a^3b^3c^3$

# Limbaje Formale, Automate și Compilatoare - Curs 1

- Prezentare curs
- 2 Limbaje formale
- Mecanisme de generare a limbajelor: gramatici
- Ierarhia lui Chomsky
- Limbaje şi gramatici de tip 3 (regulate)
- 6 Proprietăți de închidere pentru familia de limbaje regulate

Gramatici de tip 0 (generale)

Nu exista restrictii asupra regulilor

- Gramatici de tip 0 (generale)
  Nu exista restrictii asupra regulilor
- ② Gramatici de tip 1 (dependente de context) reguli de forma  $pxq \rightarrow pyq$  unde  $x \in N$ ,  $y \neq \epsilon$ ,  $p, q \in (N \cup T)^*$ ,  $S \rightarrow \epsilon$ , caz în care S nu apare în dreapta regulilor

- Gramatici de tip 0 (generale)
  Nu exista restrictii asupra regulilor
- Gramatici de tip 1 (dependente de context) reguli de forma pxq → pyq unde x ∈ N, y ≠ ε, p, q ∈ (N ∪ T)\*, S → ε, caz în care S nu apare în dreapta regulilor
- **3** Gramatici de tip 2 (independente de context) reguli de forma  $A \rightarrow y$  unde  $A \in N$  şi  $y \in (N \cup T)^*$

- Gramatici de tip 0 (generale)
  Nu exista restrictii asupra regulilor
- Gramatici de tip 1 (dependente de context) reguli de forma pxq → pyq unde x ∈ N, y ≠ ε, p, q ∈ (N ∪ T)\*, S → ε, caz în care S nu apare în dreapta regulilor
- **3** Gramatici de tip 2 (independente de context) reguli de forma  $A \rightarrow y$  unde  $A \in N$  şi  $y \in (N \cup T)^*$
- **3** Gramatici de tip 3 (regulate) reguli  $A \rightarrow u$  sau  $A \rightarrow uB$  unde  $A, B \in N$  si  $u \in T^*$ .

Ce tip au urmatoarele gramatici?

• 
$$G = (N, T, S, P), N = \{S, A, B\}, T = \{a, b, c\}, P$$
:

(1)
$$S \rightarrow aaAc$$

$$(3)bB \rightarrow bBc$$

$$(4)Bc \rightarrow Abc$$

$$(5)A \rightarrow a$$

• 
$$G = (N, T, S, P), N = \{S, X\}, T = \{a, b, c\}, P$$
:

(1)S 
$$\rightarrow$$
 abc

$$(2)S \rightarrow aSXc$$

$$(3)cX \rightarrow Xc$$

$$(4)bX \rightarrow bb$$

Fie

$$G = (\{E\}, \{a, +, -, (,)\}, E, \{E \rightarrow a, E \rightarrow (E + E), E \rightarrow (E - E)\}).$$

- Ce tip are gramatica G?
- Construiti derivari din E pentru cuvintele (a + a) si ((a + a) a)
- Cuvantul (a + a a) poate fi derivat din E?
- Descrieti limbajul L(G)
- Fie  $G = (\{A, B\}, \{a, b\}, A, \{A \rightarrow aA, A \rightarrow B, B \rightarrow bB, B \rightarrow \epsilon\})$ 
  - Ce tip are gramatica G?
  - Descrieti limbajul L(G)

## Clasificarea limbajelor

- Un limbaj L este de tipul j daca exista o gramatica G de tipul j astfel incat L(G) = L, unde j ∈ {0, 1, 2, 3}.
- Vom nota cu  $\mathcal{L}_j$  clasa limbajelor de tipul j, unde  $j \in \{0, 1, 2, 3\}$ .
- Din ierarhia lui Chomsky:  $\mathcal{L}_3 \subset \mathcal{L}_2 \subset \mathcal{L}_1 \subset \mathcal{L}_0$
- Incluziunile sunt stricte:
  - orice limbaj de tip j + 1 este si de tip  $j \in \{0, 1, 2\}$
  - exista limbaje de tip j care nu sunt de tip j + 1,  $j \in \{0, 1, 2\}$

# Proprietăți

- Fiecare din familiile  $\mathcal{L}_j$  cu  $0 \le j \le 3$  contine toate limbajele finite
- Fiecare din familiile  $\mathcal{L}_j$  cu  $0 \le j \le 3$  este inchisa la operatia de reuniune:

$$L_1, L_2 \in \mathcal{L}_j \Longrightarrow L_1 \cup L_2 \in \mathcal{L}_j,$$

$$\forall j : 0 \le j \le 3$$

# Limbaje Formale, Automate și Compilatoare - Curs 1

- Prezentare curs
- 2 Limbaje formale
- Mecanisme de generare a limbajelor: gramatici
- 4 lerarhia lui Chomsky
- Limbaje şi gramatici de tip 3 (regulate)
- Proprietăți de închidere pentru familia de limbaje regulate

## Gramatici de tip 3

- O gramatică G = (N, T, S, P) este de tip 3 dacă regulile sale au forma: A → u sau A → uB unde A, B ∈ N şi u ∈ T\*.
- Exemplu:  $G = (\{D\}, \{0, 1, ..., 9\}, D, P)$

$$D \to 0D|1D|2D|\dots|9D$$

$$D \to 0|1|\dots|9$$

Unde P este:

• Fie gramatica  $G = (\{A, B\}, \{I, d\}, A, P)$  unde P este:

$$A \rightarrow IB$$
,  $B \rightarrow IB|dB|\epsilon$  ( $I = \text{litera}$ ,  $d = \text{cifra}$ )

• Fie gramatica  $G = (\{A, B\}, \{I, d\}, A, P)$  unde P este:

$$A \rightarrow IB$$
,  $B \rightarrow IB|dB|\epsilon$  ( $I =$  litera,  $d =$  cifra)  $L(G)$ : multimea identificatorilor

• Fie gramatica  $G = (\{A, B\}, \{+, -, d\}, A, P)$  unde P este:

$$A \rightarrow +dB|-dB|dB$$
,  $B \rightarrow dB|\epsilon$  ( $d = cifra$ )

• Fie gramatica  $G = (\{A, B\}, \{I, d\}, A, P)$  unde P este:

$$A \rightarrow IB, B \rightarrow IB|dB|\epsilon$$
 (I = litera, d = cifra)

L(G): multimea identificatorilor

• Fie gramatica  $G = (\{A, B\}, \{+, -, d\}, A, P)$  unde P este:

$$A \rightarrow +dB|-dB|dB$$
,  $B \rightarrow dB|\epsilon$  ( $d = cifra$ )

*L*(*G*): multimea constantelor intregi

#### Forma normală

 O gramatică de tip 3 este in formă normală daca regulile sale sunt de forma A → a sau A → aB, unde a ∈ T, si, eventual S → ε ( caz in care S nu apare in dreapta regulilor).

 Pentru orice gramatica de tip 3 exista o gramatica echivalenta in forma normala.

#### Forma normală

- Obtinerea gramaticii in forma normala echivalenta cu o gramatica de tip 3:
  - Se poate arata ca pot fi eliminate regulile de forma A → B
     (redenumiri) si cele de forma A → ε (reguli de stergere), cu
     exceptia, eventual a regulii S → ε.
  - Orice regula de forma  $A \to a_1 a_2 \dots a_n$  se inlocuieste cu  $A \to a_1 B_1, B_1 \to a_2 B_2, \dots, B_{n-2} \to a_{n-1} B_{n-1}, B_{n-1} \to a_n, n > 1, B_1, \dots, B_{n-1}$  fiind neterminali noi.
  - Orice regula de forma  $A \to a_1 a_2 \dots a_n B$  se inlocuieste cu  $A \to a_1 B_1$ ,  $B_1 \to a_2 B_2, \dots, B_{n-2} \to a_{n-1} B_{n-1}, B_{n-1} \to a_n B, n > 1, B_1, \dots, B_{n-1}$  fiind neterminali noi
  - Transformarile care se fac nu modifica limbajul generat de gramatica

# Limbaje Formale, Automate și Compilatoare - Curs 1

- Prezentare curs
- 2 Limbaje formale
- Mecanisme de generare a limbajelor: gramatici
- Ierarhia lui Chomsky
- 5 Limbaje şi gramatici de tip 3 (regulate)
- Proprietăţi de închidere pentru familia de limbaje regulate

Fie  $L, L_1, L_2$  limbaje de tip 3 (regulate).

Atunci, urmatoarele limbaje sunt de asemenea de tip 3:

- $\bullet$   $L_1 \cup L_2$
- $\bullet$   $L_1 \cdot L_2$
- L\*
- L<sup>R</sup>
- $\bullet$   $L_1 \cap L_2$
- $\bullet$   $L_1 \setminus L_2$

#### Închiderea la reununiune

Fie  $L, L_1, L_2$  limbaje de tip 3 (regulate).

Fie 
$$G_1 = (N_1, T_1, S_1, P_1)$$
 si  $G_2 = (N_2, T_2, S_2, P_2)$  gramatici de tip 3 cu  $L_1 = L(G_1)$ ,  $L_2 = L(G_2)$ .

Presupunem  $N_1 \cap N2 = \emptyset$  si gramaticile in forma normala.

Închiderea la reuniune: se arata ca  $L_1 \cup L_2 \in \mathcal{L}_3$ :

Gramatica 
$$G = (N_1 \cup N_2 \cup \{S\}, T_1 \cup T_2, S, P_1 \cup P_2 \cup \{S \rightarrow S_1, S \rightarrow S_2\})$$
 este de tip 3 si genereaza limbajul  $L_1 \cup L_2$ 

LFAC (2016-17) Curs 1 35/37

# Închiderea la operația de produs

Fie  $L_1, L_2$  limbaje de tip 3 (regulate).

Fie 
$$G_1 = (N_1, T_1, S_1, P_1)$$
 si  $G_2 = (N_2, T_2, S_2, P_2)$  gramatici de tip 3 cu  $L_1 = L(G_1)$ ,  $L_2 = L(G_2)$ .

Presupunem  $N_1 \cap N2 = \emptyset$  si gramaticile in forma normala.

Gramatica  $G = (N_1 \cup N_2, T_1 \cup T_2, S_1, P)$  unde P consta din:

- regulile de forma A → aB din P<sub>1</sub>
- reguli A → aS<sub>2</sub> pentru orice regula de forma A → a din P<sub>1</sub>
- toate regulile din P<sub>2</sub>

este de tip 3 si genereaza limbajul  $L_1L_2$ .